

Preface

写在前面的话

此笔记是基于 某个笔记 增删该而来，如有侵权，请联系我哦! 当然有错误也可以联系我哦！

目前此笔记尚未开源，如有用于商业用途请联系我！

联系方式：[发送邮件](#)

预备知识

向量Vector

- 线性相关

存在一组 a_1, a_2, \dots, a_k 不全为零的数，使得 $a_1 \vec{x}_1 + a_2 \vec{x}_2 + \dots + a_k \vec{x}_k = \vec{0}$ ，那么可以称这组向量 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_k$ 是线性相关的。

- 线性无关

当且仅当 a_1, a_2, \dots, a_k 全都为0时， $a_1 \vec{x}_1 + a_2 \vec{x}_2 + \dots + a_k \vec{x}_k = \vec{0}$ 才成立，那么可以称这组向量 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_k$ 是线性无关的。

- 极大线性无关组

如果线性无关的 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_k$ 是向量组 \vec{x} 部分组，且 \vec{x} 中任一向量都可以用 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_k$ 表示，那么 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_k$ 就是一个极大线性无关组或最大线性无关组。

- 向量运算

内积 $\vec{a} \cdot \vec{b} = \sum a_i b_i$

$$\text{叉积 } \vec{a} \times \vec{b} = \begin{bmatrix} \vec{i} & \vec{j} & \vec{k} \\ a_x & a_y & a_z \\ b_x & b_y & b_z \end{bmatrix}$$

- 范数

- $\|x\|_1 = \sum |x_i|$
- $\|x\|_2 = \sqrt{\sum_i x_i^2}$
- $\|x\|_\infty = \max\{|x_i|\}$
- $\|x\|_p = (\sum |x_i|^p)^{\frac{1}{p}}$
- 向量范数的性质：1) 非负性；2) 齐次性；3) 三角不等性

矩阵Matrix

- 矩阵转置

$$A^T = \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{nn} \end{bmatrix}$$

$$(AB)^T = B^T A^T$$

$$(A + B)^T = A^T + B^T$$

$$(kA)^T = kA^T$$

- 共轭转置

$$A^H = (\bar{A})^T$$

eg.

$$\begin{pmatrix} 1 & 2+i \\ 1-i & 2 \end{pmatrix}^H = \begin{pmatrix} 1 & 1+i \\ 2-i & 2 \end{pmatrix}$$

- 伴随矩阵

$$A^* = \begin{bmatrix} A_{11} & A_{21} & \cdots & A_{n1} \\ A_{12} & A_{22} & \cdots & A_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ A_{1n} & A_{2n} & \cdots & A_{nn} \end{bmatrix}$$

$$A_{ij} = (-1)^{i+j} M_{ij}$$

- 矩阵的迹

$$tr(A) = \sum_i^n a_{ii} = \sum_i^n \lambda_i$$

$$a = tr(a)$$

$$tr(AB) = tr(BA)$$

$$tr(A + B) = tr(A) + tr(B)$$

$$tr(A) = tr(A^T)$$

$$tr(A^T B) = \sum_{i,j} A_{ij} B_{ij}$$

$$tr(A^T (B \odot C)) = tr((A \odot B)^T C)$$

- 范数

$$\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \text{tr}(AA^T)$$

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} = \delta_{\max}(A)$$

$$\|A\|_1 = \max_j \sum_{i=1}^n |a_{ij}|$$

$$\|A\|_\infty = \max_i \sum_{j=1}^n |a_{ij}|$$

$$\|A\|_* = \sum \delta(A)$$

$$\|A\|_p = \max_{\|x\|_p=1} \|Ax\|_p$$

- 标准正交矩阵 $U = [\alpha_1, \alpha_2, \dots, \alpha_n]$

$$\alpha_i^T \alpha_j = \begin{cases} 1, & i \neq j \\ 0, & i = j \end{cases}$$

满足如下性质：

1. $U^{-1} = U^T$
2. $\text{rank}(U) = n$
3. $U^T U = U U^T = E$
4. $\|U \cdot A\| = \|A\|$

- 部分列正交矩阵 $U = [U_1, U_2]$

$$U_1 = [u_1, u_2, \dots, u_r] \in R^{n \times r}$$

$$u_i^T u_j = \begin{cases} 1, & i \neq j \\ 0, & i = j \end{cases}$$

$$U_1^T U_1 = E_{r \times r}$$

$$U U^T = [U_1, U_2] \begin{pmatrix} U_1 \\ U_2 \end{pmatrix} = U_1 U_1^T + U_2 U_2^T = E$$

U_2 是正交补

- 正交化

有一组向量 a_1, a_2, \dots, a_n 寻找 q_1, q_2, \dots, q_n 使得

$$\text{span}\{a_1, a_2, \dots, a_n\} = \text{span}\{q_1, q_2, \dots, q_n\}$$

且 $Q = [q_1, q_2, \dots, q_n]$ 是标准正交矩阵

Gram-Schmidt

1. $\text{span}\{q_1\} = \text{span}\{a_1\}$, 则 $q_1 = \frac{a_1}{\|a_1\|}$
2. 假设 $\text{span}\{a_1, a_2, \dots, a_k\} = \text{span}\{q_1, q_2, \dots, q_k\}$ 且满足 $q_i \perp q_j, i \neq j, \|q_i\| = 1$
3. 如何构造 q_{k+1} 使其满足:
$$\begin{cases} \text{span}\{q_1, q_2, \dots, q_k\} \oplus \text{span}\{q_{k+1}\} = \text{span}\{a_1, a_2, \dots, a_{k+1}\} \\ q_{k+1} \perp q_i, i = 1, 2, \dots, k \\ \|q_{k+1}\| = 1 \end{cases}$$

$$a_{k+1} = \sum_{i=1}^{k+1} r_{i,k+1} q_i \Rightarrow q_i^T a_{k+1} = r_{i,k+1} q_i^T q_i$$

$$q_{k+1} = \frac{a_{k+1} - \sum_{i=1}^k r_{i,k+1} q_i}{\|a_{k+1} - \sum_{i=1}^k r_{i,k+1} q_i\|}, \text{ 其中 } r_{i,k+1} = q_i^T a_{k+1}, i = 1, 2, 3, \dots, k$$

从 QR Decomposition 看 Gram-Schmidt :

$$[a_1, a_2, \dots, a_n] = [q_1, q_2, \dots, q_n] \begin{bmatrix} r_{11} & r_{12} & \dots & r_{1n} \\ 0 & r_{22} & \dots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & r_{nn} \end{bmatrix}$$

$$\Rightarrow \begin{cases} a_1 = r_{11} q_1 \\ a_2 = r_{12} q_1 + r_{22} q_2 \\ \vdots \end{cases} \Rightarrow \begin{cases} q_1 = \frac{a_1}{\|a_1\|} \\ q_2 = \frac{a_2 - r_{12} q_1}{\|a_2 - r_{12} q_1\|} \\ \vdots \end{cases}$$

Arnoldi 分解: 在 $K_k(A, r_0) = \text{span}\{r_0, Ar_0, \dots, A^{k-1}r_0\}$ 上运用 Gram-Schmidt

1. 令 $v_1 = \frac{r_0}{\|r_0\|}$
2. 假设已构造 $\{v_1, v_2, \dots, v_k\}, v_k \in K_k(A, r_0), q_i \perp q_j, i \neq j, \|v_i\| = 1$
3. 如何构造 v_{k+1} 使其满足:
$$\begin{cases} v_{k+1} \in K_{k+1}(A, r_0) \\ v_{k+1} \perp v_i, i = 1, 2, \dots, k \\ \|v_{k+1}\| = 1 \end{cases}$$

$$v_{k+1} \in K_{k+1}(A, r_0) = K_k(A, r_0) \oplus \text{span}\{Av_k\} = \text{span}\{v_1, v_2, \dots, v_{k+1}\}$$

$$Av_k = \sum_{i=1}^{k+1} h_{i,k} v_i \Rightarrow v_i^T Av_k = h_{i,k} v_i^T v_i$$

$$v_{k+1} = \frac{Av_k - \sum_{i=1}^k h_{i,k} v_i}{\|Av_k - \sum_{i=1}^k h_{i,k} v_i\|}, \text{ 其中 } h_{i,k} = v_i^T Av_k, i = 1, 2, 3, \dots, k$$

• A-正交

\$\$

矩阵分解

矩阵微分

导数

- 标量对向量的求导

对于标量 $f, \vec{x}_{(n \times 1)}$ 有：

$$\frac{\partial f}{\partial \vec{x}} = \left[\frac{\partial f}{\partial x_i} \right]$$

- 标量对矩阵的求导

对于标量 $f, X_{(m \times n)}$ 有：

$$\frac{\partial f}{\partial X} = \left[\frac{\partial f}{\partial x_{ij}} \right]$$

我们知道标量对标量的梯度gradient和微分differentiation有这样的关系：

$$df = f'(x)dx$$

$$df = \sum_i \frac{\partial f}{\partial x_i} dx_i = \frac{\partial f}{\partial \vec{x}}^T d\vec{x}$$

那么标量对矩阵也存在：

$$df = \sum_{ij} \frac{\partial f}{\partial x_{ij}} dx_{ij} = \text{tr} \left(\frac{\partial f}{\partial X}^T dX \right)$$

例子1：已知 $f = |X|$ ，求 df ？

我们知道

$$|X| = \sum_i x_{ij} A_{ij} \quad (A_{ij} \text{代数余子式})$$

将上式代入得：

$$\frac{\partial f}{\partial X} = \left[\frac{\partial \sum_k x_{kj} A_{kj}}{\partial x_{ij}} \right] = [A_{ij}] = (X^*)^T$$

因此有

$$df = \text{tr}(\frac{\partial f}{\partial X}^T dX) = \text{tr}(X^* dX) = |X| \text{tr}(X^{-1} dX)$$

例子2：求 dX^{-1} ？

我们知道

$$XX^{-1} = E$$

对等式两边微分有

$$dXX^{-1} = dE$$

$$XdX^{-1} = -X^{-1}dX$$

因此有

$$dX^{-1} = -X^{-1}dXX^{-1}$$

例子3： $f = \vec{a}^T X \vec{b}$ ，求 $\frac{\partial f}{\partial X}$ ？

$$df = \vec{a}^T dX \vec{b} = \text{tr}(\vec{a}^T dX \vec{b}) = \text{tr}(\vec{b} \vec{a}^T dX) = \text{tr}(\frac{\partial f}{\partial X}^T dX)$$

因此 $\frac{\partial f}{\partial X} = \vec{a} \vec{b}^T$

- 复合法则

已知 $f = g(Y)$ ，且 $Y = h(X)$ ，怎么求 $\frac{\partial f}{\partial X}$ ？(其中 g 和 h 都是逐元素的函数)

$$df = \text{tr}(\frac{\partial f}{\partial Y}^T dY) = \text{tr}(\frac{\partial f}{\partial Y}^T (h'(X) \odot dX)) = \text{tr}((\frac{\partial f}{\partial Y} \odot h'(X))^T dX)$$

例子4： $loss = -\vec{y}^T \log \text{softmax}(W\vec{x})$ ，求 $\frac{\partial loss}{\partial W}$ 。 \vec{y} 是只有一个元素为1其余元素为0的向量。

$$\text{softmax}(\vec{x}) = \frac{e^{\vec{x}}}{\vec{1}^T e^{\vec{x}}}$$

$$loss = -\vec{y}^T W\vec{x} + (\vec{y}^T \vec{1}) \log(\vec{1}^T e^{W\vec{x}}) \quad (*)$$

$$d \text{ loss} = -\vec{y}^T dW\vec{x} + \frac{\vec{1}^T (e^{W\vec{x}} \odot dW\vec{x})}{\vec{1}^T e^{W\vec{x}}} \quad (**)$$

$$d \text{ loss} = -\vec{y}^T dW \vec{x} + \frac{(e^{W\vec{x}})^T dW \vec{x}}{\vec{1}^T e^{W\vec{x}}}$$

$$d \text{ loss} = \text{tr}(-\vec{y}^T dW \vec{x} + \frac{(e^{W\vec{x}})^T dW \vec{x}}{\vec{1}^T e^{W\vec{x}}})$$

$$d \text{ loss} = \text{tr}(\vec{x}(\text{softmax}(W\vec{x}) - \vec{y})^T dW)$$

$$\frac{\partial \text{ loss}}{\partial W} = (\text{softmax}(W\vec{x}) - \vec{y}) \vec{x}^T$$

注意:

(*) 式 $\log(\frac{\vec{b}}{c}) = \log \vec{b} - \vec{1} \log c$ · 且 $\vec{y}^T \vec{1} = 1$

(**) 式 $\log(\vec{1}^T e^{W\vec{x}})$ 是标量 · $e^{W\vec{x}}$ 是逐元素函数 · 因此 $d \log(\vec{1}^T e^{W\vec{x}}) = \frac{1}{\vec{1}^T e^{W\vec{x}}} \cdot \vec{1}^T (e^{W\vec{x}} \odot dW \vec{x})$

- 向量对向量求导

对于 $\vec{f}_{(m \times 1)}, \vec{x}_{(n \times 1)}$ 有:

$$\frac{\partial \vec{f}}{\partial \vec{x}} = \left[\frac{\partial f_i}{\partial x_j} \right]_{(n \times m)}$$

$$d\vec{f} = \left[\frac{\partial f_i}{\partial \vec{x}}^T \right] d\vec{x} = \frac{\partial \vec{f}}{\partial \vec{x}}^T d\vec{x}$$

- 矩阵对矩阵求导

对于矩阵 $F_{(m \times n)}, X_{(p \times q)}$ 有:

$$\frac{\partial F}{\partial X} = \left[\frac{\partial F_{ij}}{\partial x_{kl}} \right]_{(pq \times mn)}$$

矩阵向量化:

对于矩阵 $X_{(p \times q)}$ · 其矩阵向量化 $\text{vec}(X)_{(pq \times 1)} = [X_1^T, X_2^T, \dots, X_q^T]^T$, X_i 是 X 的列向量。

$$\text{vec}(A + B) = \text{vec}(A) + \text{vec}(B)$$

$$\text{vec}(\vec{a} \vec{b}^T) = \vec{b} \otimes \vec{a}$$

$$X = \sum_i X_i e_i^T$$

$$\text{vec}((AB) \otimes (CD)) = \text{vec}((A \otimes C)(B \otimes D))$$

$$vec(AXB) = vec(\sum_i AX_i e_i^T B) = \sum_i vec((AX_i)(B^T e_i)^T) = \sum_i (B^T e_i) \otimes (AX_i) = (B^T \otimes A)vec(X)$$

因此有：

$$\frac{\partial F}{\partial X} = \frac{\partial vec(F)}{\partial vec(X)}_{(pq \times mn)}$$

$$vec(dF) = \frac{\partial F^T}{\partial X} vec(dX)$$

求导时矩阵被向量化，弊端是这在一定程度破坏了矩阵的结构，会导致结果变得形式复杂；好处是多元微积分中关于 **Gradient**、**Hessian** 矩阵的结论可以沿用过来，只需将矩阵向量化。