

Preface

写在前面的话

此笔记是基于 某个笔记 增删该而来，如有侵权，请联系我哦! 当然有错误也可以联系我哦！

联系方式：[发送邮件](#)

最新下载地址:[下载地址](#)

Background

Vector

- 线性相关

存在一组 a_1, a_2, \dots, a_k 不全为零的数，使得 $a_1 \vec{x}_1 + a_2 \vec{x}_2 + \dots + a_k \vec{x}_k = \vec{0}$ ，那么可以称这组向量 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_k$ 是线性相关的。

- 线性无关

当且仅当 a_1, a_2, \dots, a_k 全都为0时， $a_1 \vec{x}_1 + a_2 \vec{x}_2 + \dots + a_k \vec{x}_k = \vec{0}$ 才成立，那么可以称这组向量 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_k$ 是线性无关的。

- 极大线性无关组

如果线性无关的 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_k$ 是向量组 \vec{x} 部分组，且 \vec{x} 中任一向量都可以用 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_k$ 表示，那么 $\vec{x}_1, \vec{x}_2, \dots, \vec{x}_k$ 就是一个极大线性无关组或最大线性无关组。

- 向量运算

内积 $\vec{a} \cdot \vec{b} = \sum a_i b_i$

$$\text{叉积 } \vec{a} \times \vec{b} = \begin{bmatrix} \vec{i} & \vec{j} & \vec{k} \\ a_x & a_y & a_z \\ b_x & b_y & b_z \end{bmatrix}$$

- 范数

- $\|x\|_1 = \sum |x_i|$
- $\|x\|_2 = \sqrt{\sum_i x_i^2}$
- $\|x\|_\infty = \max\{|x_i|\}$
- $\|x\|_p = (\sum |x_i|^p)^{\frac{1}{p}}$
- 向量范数的性质：

- $\|x\| \geq 0$
- $\|kx\| = |k| \|x\|$
- $\|x + y\| \leq \|x\| + \|y\|$

Matrix

- 矩阵转置

$$A^T = \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & \cdots & a_{nn} \end{bmatrix}$$

$$(AB)^T = B^T A^T$$

$$(A+B)^T = A^T + B^T$$

$$(kA)^T = kA^T$$

- 共轭转置

$$A^H = (\bar{A})^T$$

eg.

$$\begin{pmatrix} 1 & 2+i \\ 1-i & 2 \end{pmatrix}^H = \begin{pmatrix} 1 & 1+i \\ 2-i & 2 \end{pmatrix}$$

酉矩阵：复数域上的正交矩阵 $u_i^H u_j = \begin{cases} 0, & i \neq j \\ 1, & i = j \end{cases}$

Hermitian 矩阵： $A^H = A$ · 例如 $U_1 U_1^H = (U_1 U_1^H)^H$

- 伴随矩阵

$$A^* = \begin{bmatrix} A_{11} & A_{21} & \cdots & A_{n1} \\ A_{12} & A_{22} & \cdots & A_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ A_{1n} & A_{2n} & \cdots & A_{nn} \end{bmatrix}$$

$$A_{ij} = (-1)^{i+j} M_{ij}$$

- 矩阵的迹

$$tr(A) = \sum_i^n a_{ii} = \sum_i^n \lambda_i$$

$$a = tr(a)$$

$$tr(AB) = tr(BA)$$

$$tr(A+B) = tr(A) + tr(B)$$

$$tr(A) = tr(A^T)$$

$$tr(A^T B) = \sum_{i,j} A_{ij} B_{ij}$$

$$tr(A^T (B \odot C)) = tr((A \odot B)^T C)$$

- 范数

$$\|A\|_F = \sqrt{\sum_{i,j} a_{ij}^2} = \text{tr}(AA^T)$$

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} = \delta_{\max}(A)$$

$$\|A\|_1 = \max_j \sum_{i=1}^n |a_{ij}|$$

$$\|A\|_{\infty} = \max_i \sum_{j=1}^n |a_{ij}|$$

$$\|A\|_* = \sum \delta(A)$$

$$\|A\|_p = \max_{\|x\|_p=1} \|Ax\|_p$$

矩阵范数满足：

1. $\|A\| \geq 0$
2. $\|kA\| = k \|A\|$
3. $\|A + B\| \leq \|A\| + \|B\|$
4. $\|AB\| \leq \|A\| \cdot \|B\|$

- 谱半径

$$\rho(A) = \max |\lambda(A)|$$

1. 谱半径不是范数
2. 若A是 Hermitian 矩阵, 则 $\rho(A) = \|A\|_2$
3. $\rho(A) = \inf_{\|\cdot\|} \|A\|$
4. $\sum_k A^k$ 收敛 $\Rightarrow A^k \rightarrow 0, \rho(A) < 1$
5. $\|A^k\|^{\frac{1}{k}} \rightarrow \rho(A)$

- 标准正交矩阵 $U = [\alpha_1, \alpha_2, \dots, \alpha_n]$

$$\alpha_i^T \alpha_j = \begin{cases} 1, & i \neq j \\ 0, & i = j \end{cases}$$

满足如下性质：

1. $U^{-1} = U^T$
2. $\text{rank}(U) = n$

$$3. U^T U = U U^T = E$$

$$4. \|U \cdot A\| = \|A\|$$

- 部分列正交矩阵 $U = [U_1, U_2]$

$$U_1 = [u_1, u_2, \dots, u_r] \in R^{n \times r}$$

$$u_i^T u_j = \begin{cases} 0, & i \neq j \\ 1, & i = j \end{cases}$$

$$U_1^T U_1 = E_{r \times r}$$

$$U U^T = [U_1, U_2] \begin{pmatrix} U_1 \\ U_2 \end{pmatrix} = U_1 U_1^T + U_2 U_2^T = E$$

U_2 是正交补

- 正交化

有一组向量 a_1, a_2, \dots, a_n 寻找 q_1, q_2, \dots, q_n 使得

$$\text{span}\{a_1, a_2, \dots, a_n\} = \text{span}\{q_1, q_2, \dots, q_n\}$$

且 $Q = [q_1, q_2, \dots, q_n]$ 是标准正交矩阵

Gram-Schmidt

$$1. \text{span}\{q_1\} = \text{span}\{a_1\}, \text{ 则 } q_1 = \frac{a_1}{\|a_1\|}$$

$$2. \text{ 假设 } \text{span}\{a_1, a_2, \dots, a_k\} = \text{span}\{q_1, q_2, \dots, q_k\} \text{ 且满足 } q_i \perp q_j, i \neq j, \|q_i\| = 1$$

$$3. \text{ 如何构造 } q_{k+1} \text{ 使其满足: } \begin{cases} \text{span}\{q_1, q_2, \dots, q_k\} \oplus \text{span}\{q_{k+1}\} = \text{span}\{a_1, a_2, \dots, a_{k+1}\} \\ q_{k+1} \perp q_i, i = 1, 2, \dots, k \\ \|q_{k+1}\| = 1 \end{cases}$$

$$a_{k+1} = \sum_{i=1}^{k+1} r_{i,k+1} q_i \Rightarrow q_i^T a_{k+1} = r_{i,k+1} q_i^T q_i$$

$$q_{k+1} = \frac{a_{k+1} - \sum_{i=1}^k r_{i,k+1} q_i}{\|a_{k+1} - \sum_{i=1}^k r_{i,k+1} q_i\|}, \text{ 其中 } r_{i,k+1} = q_i^T a_{k+1}, i = 1, 2, 3, \dots, k$$

从 QR Decomposition 看 Gram-Schmidt :

$$[a_1, a_2, \dots, a_n] = [q_1, q_2, \dots, q_n] \begin{bmatrix} r_{11} & r_{12} & \dots & r_{1n} \\ 0 & r_{22} & \dots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & r_{nn} \end{bmatrix}$$

$$\Rightarrow \begin{cases} a_1 = r_{11} q_1 \\ a_2 = r_{12} q_1 + r_{22} q_2 \\ \vdots \end{cases} \Rightarrow \begin{cases} q_1 = \frac{a_1}{\|a_1\|} \\ q_2 = \frac{a_2 - r_{12} q_1}{\|a_2 - r_{12} q_1\|} \\ \vdots \end{cases}$$

Arnoldi 分解 : 在 $K_k(A, r_0) = \text{span}\{r_0, Ar_0, \dots, A^{k-1} r_0\}$ 上运用 Gram-Schmidt

$$1. \text{ 令 } v_1 = \frac{r_0}{\|r_0\|}$$

$$2. \text{ 假设已构造 } \{v_1, v_2, \dots, v_k\}, v_k \in K_k(A, r_0), q_i \perp q_j, i \neq j, \|v_i\| = 1$$

3. 如何构造 v_{k+1} 使其满足：

$$\begin{cases} v_{k+1} \in K_{k+1}(A, r_0) \\ v_{k+1} \perp v_i, i = 1, 2, \dots, k \\ \|v_{k+1}\| = 1 \end{cases}$$

$$v_{k+1} \in K_{k+1}(A, r_0) = K_k(A, r_0) \oplus \text{span}\{Av_k\} = \text{span}\{v_1, v_2, \dots, v_{k+1}\}$$

$$Av_k = \sum_{i=1}^{k+1} h_{i,k} v_i \Rightarrow v_i^T Av_k = h_{i,k} v_i^T v_i$$

$$v_{k+1} = \frac{Av_k - \sum_{i=1}^k h_{i,k} v_i}{\|Av_k - \sum_{i=1}^k h_{i,k} v_i\|}, \text{ 其中 } h_{i,k} = v_i^T Av_k, i = 1, 2, 3, \dots, k$$

- A-正交

$$\|X\|_A = \sqrt{X^T A X}$$

有一组向量 a_1, a_2, \dots, a_n 寻找 q_1, q_2, \dots, q_n 使得

$$\text{span}\{a_1, a_2, \dots, a_n\} = \text{span}\{q_1, q_2, \dots, q_n\}$$

且 q_1, q_2, \dots, q_n 与 A 正交，即 $q_i^T A q_j = \begin{cases} \neq 0, & i = j \\ 0, & i \neq j \end{cases}$

做法同上，这里就不赘述。

- 广义逆

对 $A = U_1 \Sigma_1 V_1^H \in C^{m \times n}$ ，记 $A^+ = V_1 \Sigma_1^{-1} U_1^H$ ，满足：

1. $A^+ A A^+ = A^+$

2. $A A^+ A = A$

3. $A A^+, A^+ A$ 都是 Hermitian


- 正交投影

假设 p 是子空间 $W : \text{span}\{U_1\}$ 的投影， $p = U_1 U_1^H$ ， U_1 是酉阵，则有如下性质：

1. $p^H = p$

2. $p^2 = p$

3. $\forall x, px \in W$ 且 $(px)^H (x - px) = 0$



- 子空间

- 子空间距离

- 点到子空间距离和 $\text{span}\{x\}$ 到子空间的距离

具体参考正交投影

- 两个平面以及同维子空间距离

Z, Y 分别是其标准正交基

$$\text{dist}(\mathfrak{X}, \mathfrak{Y}) = \sqrt{1 - \sigma_{\min}^2(Z^H Y)}$$

- Krylov 子空间

$$K_k(A, r_0) = \text{span}\{r_0, Ar_0, \dots, A^{k-1} r_0\}$$

Matrix Decomposition

$A \in C^{n \times n}, B \in C^{m \times n}$, U, V 为酉阵

QR Decomposition

$$A = [a_1, a_2, \cdots, a_n] = Q \cdot R = [q_1, q_2, \cdots, q_n] \begin{bmatrix} r_{11} & r_{12} & \cdots & r_{1n} \\ 0 & r_{22} & \cdots & r_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & r_{nn} \end{bmatrix}$$

LU Decomposition

$$A = L \cdot U$$

L 为上三角矩阵 · U 为下三角矩阵

$$Ax = b \Rightarrow (LU)x = b \Rightarrow \begin{cases} Ly = b \\ Ux = y \end{cases}$$

Shur Decomposition

$$A = URU^H$$

其中 U 是正交阵 · R 是上三角阵。

若 A 是 Hermitian 矩阵 · 则 R 是对角阵 · 即 $A = U\Lambda U^T$

Singular Value Decompostion

$$B = U\Sigma V^H$$

若 $rank(B) = r$, 则有

$$A = (u_1, u_2, \cdots, u_m) \begin{pmatrix} \sigma_1 & & & & \\ & \ddots & & & \\ & & \sigma_r & & \\ & & & 0 & \\ & & & & \ddots \\ & & & & & 0 \end{pmatrix}_{m \times n} (v_1, v_2, \cdots, v_n)^H = U_1 \Sigma_1 V_1^H$$

其中 · $U_1 = (u_1, u_2, \cdots, u_r), V_1 = (v_1, v_2, \cdots, v_r)$

因此根据 $B = U\Sigma V^H$, 可以得到

$$Av_i = U\Sigma \begin{pmatrix} v_1^H \\ \vdots \\ v_n^H \end{pmatrix} v_i = \sigma_i u_i$$

$$u_i^H A = u_i^H (u_1, u_2, \dots, u_m) \Sigma V^H = \sigma_i v_i^H$$

思考：什么情况下奇异值与特征值相同？

$$A^H A = V\Sigma^H U^H U \Sigma V^H = V\Sigma^H \Sigma V^H$$

$$A A^H = U\Sigma V^H V \Sigma^H U^H = U\Sigma^H \Sigma U^H$$

因此我们可以根据以上两个矩阵的特征值已经特征向量得到矩阵A的奇异值和奇异向量。

例题： $W = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$

$$W^H W = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

特征值：3,1

$$\text{特征向量 } v_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}, v_2 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} \end{bmatrix}$$

$$W W^H = \begin{bmatrix} 2 & 1 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$


特征值：3,1,0

$$\text{特征向量 } u_1 = \begin{bmatrix} \frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \end{bmatrix}, u_2 = \begin{bmatrix} 0 \\ -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}, u_3 = \begin{bmatrix} -\frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{3}} \end{bmatrix}$$

$$\text{因此 } W = (u_1, u_2, u_3) \begin{bmatrix} \frac{1}{\sqrt{3}} & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} (v_1, v_2)$$

Householder Transformation

要求实现 $Hx = y, \|x\| = \|y\|$, 要求：1) $H^H = H$, 2) H 是酉阵



$$y = x - 2 \frac{x-y}{2}$$

由于 $\|x\| = \|y\|$, 因此 $x, y, x - y$ 构成等腰三角形

因此根据正交投影可知 $\frac{x-y}{2} = px$, $p = uu^H$ 是 $\text{span}\{x - y\}$ 的正交投影, $u = \frac{x-y}{\|x-y\|}$

$\therefore H = I - 2uu^H$, 显然满足上述两点。

利用 Householder Transformation 可以将矩阵稀疏化。

$$\begin{bmatrix} * & * & * & * \\ * & * & * & * \\ 0 & * & * & * \\ 0 & 0 & * & * \end{bmatrix} \xrightarrow{H} \begin{bmatrix} * & * & * & * \\ 0 & * & * & * \\ 0 & 0 & * & * \\ 0 & 0 & 0 & * \end{bmatrix}$$

注意可以跨行和列去选择变换

$$\begin{bmatrix} * & 0 & 0 \\ * & * & 0 \\ * & * & * \\ * & * & * \\ * & * & * \\ * & * & * \end{bmatrix} \xrightarrow{H} \begin{bmatrix} * & 0 & 0 \\ * & * & 0 \\ * & * & * \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

同样也能用 Householder Transformation 求QR分解

Givens Rotation Transformation

$$\begin{bmatrix} C & S \\ -S & C \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sqrt{a^2 + b^2} \\ 0 \end{bmatrix} \cdot \text{其中 } C = \frac{a}{\sqrt{a^2 + b^2}}, S = \frac{b}{\sqrt{a^2 + b^2}}$$

同样也能用 Givens Rotation Transformation 求QR分解

Application

- 标准正交基
 - $R(A) = \{Ax | x \in R^n\}$
 $\because Ax = U_1 \Sigma_1 V_1^H x = U_1 Z$
 $\therefore R(A) = \text{span}\{U_1\}, R(A^H) = \text{span}\{V_1\}$
 - $N(A) = \{x | Ax = 0\}$
 $\because Ax = U_1 \Sigma_1 V_1^H x = 0 \Rightarrow V_1^H x = 0$
 $\therefore N(A) = \text{span}\{V_2\}, N(A^H) = \text{span}\{U_2\}$

- 低秩逼近
 设 $\text{rank}(A) = r, d < r$, 求 $\min_{\text{rank}(x)=d} \|A - x\|_2$ 。

- 最小二乘法
 $\min_x \|Ax - b\|_2 \Rightarrow \min_{y \in R(A)} \|b - y\|_2$
 $Ax = AA^+b$ 的通解为齐次解加上特解，其特解为 A^+b , 齐次通解为 $\sigma = (I - A^+A)z \in N(A)$
 因此 $x = A^+b + (I - A^+A)z$

Matrix Differential

导数与微分

- 标量对向量的求导
 对于标量 $f, \vec{x}_{(n \times 1)}$ 有：

$$\frac{\partial f}{\partial \vec{x}} = \left[\frac{\partial f}{\partial x_i} \right]$$

- 标量对矩阵的求导

对于标量 $f, X_{(m \times n)}$ 有：

$$\frac{\partial f}{\partial X} = \left[\frac{\partial f}{\partial x_{ij}} \right]$$

我们知道标量对标量的梯度gradient和微分differentiation有这样的关系：

$$df = f'(x)dx$$

$$df = \sum_i \frac{\partial f}{\partial x_i} dx_i = \frac{\partial f}{\partial \vec{x}}^T d\vec{x}$$

那么标量对矩阵也存在：

$$df = \sum_{ij} \frac{\partial f}{\partial x_{ij}} dx_{ij} = \text{tr} \left(\frac{\partial f}{\partial X}^T dX \right)$$

例子1：已知 $f = |X|$ ，求 df ？

我们知道

$$|X| = \sum_i x_{ij} A_{ij} \quad (A_{ij} \text{ 代数余子式})$$

将上式代入得：

$$\frac{\partial f}{\partial X} = \left[\frac{\partial \sum_k x_{kj} A_{kj}}{\partial x_{ij}} \right] = [A_{ij}] = (X^*)^T$$

因此有

$$df = \text{tr} \left(\frac{\partial f}{\partial X}^T dX \right) = \text{tr}(X^* dX) = |X| \text{tr}(X^{-1} dX)$$

例子2：求 dX^{-1} ？

我们知道

$$XX^{-1} = E$$

对等式两边微分有

$$dXX^{-1} = dE$$

$$X dX^{-1} = -X^{-1} dX$$

因此有

$$dX^{-1} = -X^{-1} dX X^{-1}$$

例子3: $f = \vec{a}^T X \vec{b}$ · 求 $\frac{\partial f}{\partial X}$?

$$df = \vec{a}^T dX \vec{b} = \text{tr}(\vec{a}^T dX \vec{b}) = \text{tr}(\vec{b} \vec{a}^T dX) = \text{tr}(\frac{\partial f}{\partial X}^T dX)$$

因此 $\frac{\partial f}{\partial X} = \vec{a} \vec{b}^T$

• 复合法则

已知 $f = g(Y)$ · 且 $Y = h(X)$ · 怎么求 $\frac{\partial f}{\partial X}$? (其中g和h都是逐元素的函数)

$$df = \text{tr}(\frac{\partial f}{\partial Y}^T dY) = \text{tr}(\frac{\partial f}{\partial Y}^T (h'(X) \odot dX)) = \text{tr}((\frac{\partial f}{\partial Y} \odot h'(X))^T dX)$$

例子4: $loss = -\vec{y}^T \log \text{softmax}(W\vec{x})$ · 求 $\frac{\partial loss}{\partial W}$ 。 \vec{y} 是只有一个元素为1其余元素为0的向量。

$$\text{softmax}(\vec{x}) = \frac{e^{\vec{x}}}{\vec{1}^T e^{\vec{x}}}$$

$$loss = -\vec{y}^T W \vec{x} + (\vec{y}^T \vec{1}) \log(\vec{1}^T e^{W \vec{x}}) \quad (*)$$

$$d \text{ loss} = -\vec{y}^T dW \vec{x} + \frac{\vec{1}^T (e^{W \vec{x}} \odot dW \vec{x})}{\vec{1}^T e^{W \vec{x}}} \quad (**)$$

$$d \text{ loss} = -\vec{y}^T dW \vec{x} + \frac{(e^{W \vec{x}})^T dW \vec{x}}{\vec{1}^T e^{W \vec{x}}}$$

$$d \text{ loss} = \text{tr}(-\vec{y}^T dW \vec{x} + \frac{(e^{W \vec{x}})^T dW \vec{x}}{\vec{1}^T e^{W \vec{x}}})$$

$$d \text{ loss} = \text{tr}(\vec{x}(\text{softmax}(W \vec{x}) - \vec{y})^T dW)$$

$$\frac{\partial loss}{\partial W} = (softmax(W\vec{x}) - \vec{y})\vec{x}^T$$

注意:

(*)式 $\log(\frac{\vec{b}}{c}) = \log \vec{b} - \vec{1} \log c$, 且 $\vec{y}^T \vec{1} = 1$

(**)式 $\log(\vec{1}^T e^{W\vec{x}})$ 是标量 , $e^{W\vec{x}}$ 是逐元素函数 , 因此 $d \log(\vec{1}^T e^{W\vec{x}}) = \frac{1}{\vec{1}^T e^{W\vec{x}}} \cdot \vec{1}^T (e^{W\vec{x}} \odot dW\vec{x})$

- 向量对向量求导

对于 $\vec{f}_{(m \times 1)}, \vec{x}_{(n \times 1)}$ 有 :

$$\frac{\partial \vec{f}}{\partial \vec{x}} = \left[\frac{\partial f_i}{\partial x_j} \right]_{(n \times m)}$$

$$d\vec{f} = \left[\frac{\partial f_i}{\partial \vec{x}}^T \right] d\vec{x} = \frac{\partial \vec{f}}{\partial \vec{x}}^T d\vec{x}$$

- 矩阵对矩阵求导

对于矩阵 $F_{(m \times n)}, X_{(p \times q)}$ 有 :

$$\frac{\partial F}{\partial X} = \left[\frac{\partial F_{ij}}{\partial x_{kl}} \right]_{(pq \times mn)}$$

矩阵向量化 :

对于矩阵 $X_{(p \times q)}$, 其矩阵向量化 $vec(X)_{(pq \times 1)} = [X_1^T, X_2^T, ..., X_q^T]^T$, X_i 是 X 的列向量。

$$vec(A + B) = vec(A) + vec(B)$$

$$vec(\vec{a}\vec{b}^T) = \vec{b} \otimes \vec{a}$$

$$X = \sum_i X_i e_i^T$$

$$vec((AB) \otimes (CD)) = vec((A \otimes C)(B \otimes D))$$

$$vec(AXB) = vec\left(\sum_i AX_i e_i^T B\right) = \sum_i vec((AX_i)(B^T e_i)^T) = \sum_i (B^T e_i) \otimes (AX_i) = (B^T \otimes A)vec(X)$$

因此有 :

$$\frac{\partial F}{\partial X} = \frac{\partial \text{vec}(F)}{\partial \text{vec}(X)}_{(pq \times mn)}$$

$$\text{vec}(dF) = \frac{\partial F^T}{\partial X} \text{vec}(dX)$$

求导时矩阵被向量化，弊端是这在一定程度破坏了矩阵的结构，会导致结果变得形式复杂；好处是多元微积分中关于 Gradient、Hessian 矩阵的结论可以沿用过来，只需将矩阵向量化。

应用

1. 紧紧抓住两个转换公式： $df = \text{tr}(\frac{\partial f}{\partial X}^T dX)$, $d(\text{trace}(f(X))) = \text{trace}(df(X))$ 以及定义，那么几乎所有的导数我们都能求。

2. 泰勒公式

3. 求最优化问题

◦ 最小二乘法：

- $\min_x \|Ax - b\|_2^2$
- $\min_x \|Ax - b\|_2^2 + \lambda \|x\|_2^2$

◦ 有约束问题：

- $\min_x \|Ax\|_2^2, s.t. e^T x = 1$ 或者 $s.t. \|x\|_2 = 1$
- $\min_U \text{tr}(U^T A U), s.t. U^H U = I, A$ 半正定
- $\min_X [\text{tr}(X^T X) - 2\text{tr}(X)], s.t. XA = 0$

◦ Locally Linear Embedding

给定一组数据 $x_i \in R^n$ 及其邻域数据 $x_{i1}, x_{i2}, \dots, x_{ij}$ ，要求将 x_i 降维为 $y_i \in R^d$ 。

LLE 认为数据局部是线性的 $x_i = \sum_{j=1}^j w_{ij} x_{ij}$ ，且在降维过程中线性不变，且组合系数不变。

优化目标： $\arg \min_Y \sum_{i=1}^N \left\| y_i - \sum_{j=1}^k w_{ij} y_{ij} \right\|_2^2, s.t. Y Y^T = N I$

4. 总体最小二乘

$$(A + \Delta A)x = (b + \Delta b) \Rightarrow ([A, b] + [\Delta A, \Delta b]) \begin{bmatrix} x \\ -1 \end{bmatrix} = 0$$

令 $B = [A, b], D = [\Delta A, \Delta b], Z = \begin{bmatrix} x \\ -1 \end{bmatrix}$

因此要求 x 的近似解即求： $\min_{D, x} \|D\|_F^2, s.t. (B + D)Z = 0$

◦ 若 B 不是列满秩，则存在 $Z \neq 0, BZ = 0$ ，要使 $\min_{D, x} \|D\|_F^2$ 最小，只需 $D = 0$

◦ 若 B 是列满秩，要使 $(B + D)Z = 0$ 有解，则 $r(B + D) \leq n$

▪ 若 B 的奇异值满足 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_n \geq \sigma_{n+1}$

要使 $\min_{D, x} \|D\|_F^2$ 最小，只需 $D = -\sigma_{n+1} u_{n+1} v_{n+1}^T$

故 $N(B + D) = \text{span}\{v_{n+1}\}$

记 $v_{n+1} = (v_{n+1,1}, v_{n+1,2}, \dots, v_{n+1,n+1})^T$

$$\text{因此} \begin{pmatrix} x \\ -1 \end{pmatrix} = \begin{pmatrix} -\frac{v_{n+1,1}}{v_{n+1,n+1}} \\ -\frac{v_{n+1,2}}{v_{n+1,n+1}} \\ \vdots \\ -1 \end{pmatrix}$$

- 若 B 的奇异值满足 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_p \geq \sigma_{p+1} = \dots = \sigma_{n+1}$

$$N(B + D) = \text{span}\{v_{p+1}, \dots, v_{n+1}\}$$

$$\text{记 } V_1 = (v_{p+1}, \dots, v_{n+1})^T$$

运用 Householder 变换：

$$HV_1 = \begin{pmatrix} \hat{v}_{n+1} \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

Matrix Equation

分裂迭代

方程 $Ax = b$

$$\text{令 } A = M - N \Rightarrow Mx = Nx + b$$

$$\text{迭代形式 } Mx_k = Nx_{k-1} + b$$

$$\text{故 } x_k = M^{-1}(Nx_{k-1} + b)$$

$$\text{收敛性要求: } \rho(M^{-1}N) < 1$$

若 A 正定，当且仅当 $M + N^H$ 时， $\rho(M^{-1}N) < 1$

- Jacobi 迭代

$$A = D - L - U$$

$$M = D, N = L + U = D - A$$

$$\text{故 } x_k = D^{-1}((L + U)x_{k-1} + b) = (I - D^{-1}A)x_{k-1} + D^{-1}b$$

$$\text{收敛性要求: } \rho(I - D^{-1}A) < 1$$

适用： A 对角占优

- Gauss-Seidel 迭代

$$A = D - L - U$$

$$M = D - L, N = U$$

$$\text{故 } x_k = (D - L)^{-1}(Ux_{k-1} + b)$$

$$\text{收敛性要求: } \rho((D - L)^{-1}U) < 1$$

适用：元素集中在下三角处

- SOR

$$M = \frac{1}{\omega}D - L, N = ((\frac{1}{\omega} - 1)D + U)$$

$$\text{故 } (D - \omega L)x_k = ((1 - \omega)D + \omega U)x_{k-1} + \omega b$$

$$\text{收敛性要求: } \rho((D - \omega L)^{-1}((1 - \omega)D + \omega U)) < 1, 0 < \omega < 2$$

适用：下三角占优

- SSOR

交替迭代

1. $M = \frac{1}{\omega}D - L, N = ((\frac{1}{\omega} - 1)D + U)$
2. $M = \frac{1}{\omega}D - U, N = ((\frac{1}{\omega} - 1)D + L)$

最速下降

$$Ax = b \iff \min_x \psi(x) = \frac{1}{2}(x, x)_A - (b, x)$$

A对称正定

迭代式： $x_{k+1} = x_k + \alpha_k r_k, r_k = b - Ax_k = -\nabla \psi(x_k), \alpha_k = \arg \min_{\alpha} \|x_k + \alpha r_k - x^*\|$

求 α 只需满足下式：

$$\frac{d\psi(x_k + \alpha r_k)}{d\alpha} = 0$$

$$\psi(x_k + \alpha r_k) = \psi(x_k) + \alpha(-r_k, r_k) + \frac{\alpha^2}{2}(Ar_k, r_k)$$

$$\text{故}(-r_k, r_k) + \alpha(Ar_k, r_k) = 0 \Rightarrow \alpha = \frac{\|r_k\|_2^2}{\|r_k\|_A^2}$$

$$\begin{aligned} \text{收敛性分析: } \|x_{k+1} - x^*\|_A &= \min_{\alpha} \|x_k + \alpha r_k - x^*\|_A = \min_{\alpha} \|x_k + \alpha A(x^* - x_k) - x^*\|_A \\ &= \min_{\alpha} \|(I - \alpha A)(x_k - x^*)\|_A \\ &\leq \min_{\alpha} \rho(I - \alpha A) \|x_k - x^*\|_A \\ &\leq \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1} \|x_k - x^*\|_A \\ &\leq \left(\frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}\right)^k \|x_0 - x^*\|_A \end{aligned}$$

子空间迭代

$$A \in C^{n \times n}$$

$$Ax = b \iff x = A^{-1}b \iff A(x^* - x_0) = b - Ax_0 = r_0 \iff x^* = x_0 + A^{-1}r_0$$

$$\text{又 } A^{-1} = \sum_{i=0}^m C_i A^i r_0$$

$$\text{故 } x^* = x_0 + K_{m+1}(A, r_0)$$

共轭CG

$$x^* = x_0 + K_{m+1}(A, r_0)$$

设 g_0, g_1, \dots, g_m 是 $K_{m+1}(A, r_0)$ 一组标准A正交基，则

$$x^* = x_0 + \sum_{j=0}^m \alpha_j g_j$$

设 $x_k = x_0 + \sum_{j=0}^{k-1} \alpha_j g_j$ ，则 $x_{k+1} = x_k + \alpha_k g_k$

如何确定系数 α_k 和正交基 g_k ？

1. 求 α_k

显然 $x_{m+1} = x^*$ ，那么 $r_{m+1} = b - Ax_{m+1} = b - Ax^* = 0$

$$\begin{aligned} r_{m+1} &= b - Ax_{m+1} \\ &= b - A(x_m + \alpha_m g_m) \\ &= r_m - \alpha_m Ag_m \\ &= b - Ax_m - \alpha_m Ag_m \\ &= b - A(x_{m-1} + \alpha_{m-1} g_{m-1}) - \alpha_m Ag_m \\ &= r_{m-1} - \alpha_{m-1} Ag_{m-1} - \alpha_m Ag_m \\ &= \dots \\ &= r_k - \alpha_k Ag_k - \alpha_{k+1} Ag_{k+1} - \dots - \alpha_m Ag_m \\ &= 0 \end{aligned}$$

$$\text{则 } g_k^T r_k = \alpha_k g_k^T Ag_k - \alpha_{k+1} g_k^T Ag_{k+1} - \dots - \alpha_m g_k^T Ag_m = \alpha_k g_k^T Ag_k$$

$$\therefore \alpha_k = \frac{g_k^T r_k}{g_k^T Ag_k}$$

2. 求 g_k

Gram-schmidt

1. 令 $g_0 = r_0$
2. 假设已求得 g_0, g_1, \dots, g_{k-1} ，有 $\text{span}\{g_0, g_1, \dots, g_{k-1}\} = \text{span}\{r_0, Ar_0, \dots, A^{k-1}r_0\}$
3. 对于 r_k 有：

$$\begin{aligned} r_k &= b - Ax_k \\ &= b - A(x_{k-1} + \alpha_{k-1} g_{k-1}) \\ &= r_{k-1} - \alpha_{k-1} Ag_{k-1} \\ &= \dots \\ &= r_0 - \sum_{j=0}^{k-1} \alpha_j Ag_j \in K_{k+1}(A, r_0) \end{aligned}$$

而 $g_k \in K_{k+1}(A, r_0)$ ，故 $r_k = \beta_0 g_0 + \beta_1 g_1 + \dots + \beta_k g_k$

$$\therefore g_i^T Ar_k = \beta_i g_i^T Ag_i, \quad i = 0, 1, \dots, k$$

$\therefore g_k$ 可求

收敛速度大于最速下降法

A非对称

- 直观法

将 $Ax = b$ 转化为 $A^T Ax = b$

收敛速度远小于 A 正定时收敛速度

- 广义最小残量法

前面在 Arnoldi 分解我们得到 $K_k(A, r_0)$ 的标准正交基 v_1, v_2, \dots, v_k

$$\begin{aligned} \text{令 } V_k &= (v_1, v_2, \dots, v_k) \cdot \text{则 } AV_k = V_k H_k + h_{k+1,k} v_{k+1} e_k^T = V_{k+1} \hat{H}_k \\ b - Ax_k &= b - A(x_0 + V_k y) = r_0 - V_{k+1} \hat{H}_k y = V_{k+1} (\|r_0\| e_1 - \hat{H}_k y) \\ \therefore \|b - Ax_k\|_2 &= \left\| \|r_0\| e_1 - \hat{H}_k y \right\|_2 \\ y &= \arg \min_y \left\| \|r_0\| e_1 - \hat{H}_k y \right\|_2 \end{aligned}$$

求解上述式子：

1. 最小二乘法
2. Givens旋转变换 · 对 \hat{H}_k 进行 QR 分解

Convex Optimization

次梯度

g^T 次梯度

1. 向量： $f(y) \geq f(x) + g^T(y - x)$
2. 矩阵： $f(Y) \geq f(X) + \text{trace}(g^T(Y - X))$

例题：求和范数的次梯度 $\partial \|X\|_*$

$$\begin{aligned} f(X) &\geq f(0) + \text{trace}(g^T X) \Rightarrow \sum \sigma_i \geq \text{trace}(g^T X) \\ \text{tr}(\Sigma_1) &\geq \text{tr}(g^T U_1 \Sigma_1 V_1^T) \Rightarrow \text{tr}(V_1 \Sigma_1 V_1^T) \geq \text{tr}(g^T U_1 \Sigma_1 V_1^T) \\ \therefore \partial \|X\|_* &= \{U_1 V_1^T + Y \mid U_1^T Y = 0, Y V_1 = 0, \|X\|_2 \leq 1\} \end{aligned}$$

Solving Characteristic Value